

Conceptos Fundamentales del Manejo de Datos

ETL, EDA, SQL, NoSQL, MongoDB y Transformación de Datos

Índice

1. ¿Qué es un ETL?	2
2. ¿Qué es un EDA?	2
3. ¿Qué es SQL?	3
4. ¿Qué es NoSQL?	3
5. ¿Qué es MongoDB?	4
6. 8 Pasos de la Transformación de Datos	4
7. ¿Qué hacer si tengo datos nulos?	5

1 ¿Qué es un ETL?

Definición

ETL (*Extract, Transform, Load* — Extraer, Transformar y Cargar) es un proceso que permite mover datos desde una o varias fuentes de origen hacia un destino (como un almacén de datos o *data warehouse*), transformándolos en el camino para que sean útiles, consistentes y estén listos para el análisis.

Las tres fases

1. **Extract (Extracción):** obtención de datos desde múltiples fuentes (bases de datos, APIs, archivos planos, sensores, etc.).
2. **Transform (Transformación):** limpieza, estandarización, filtrado, agregación y aplicación de reglas de negocio a los datos extraídos.
3. **Load (Carga):** inserción de los datos ya transformados en el sistema destino (*data warehouse*, base de datos analítica, etc.).

¿Para qué sirve?

Permite consolidar información dispersa en un solo lugar, garantizar su calidad y dejarla disponible para *reportes*, *dashboards* y modelos de *Business Intelligence*.

2 ¿Qué es un EDA?

Definición

EDA (*Exploratory Data Analysis* — Análisis Exploratorio de Datos) es el proceso de investigar y resumir un conjunto de datos para descubrir patrones, detectar anomalías, comprobar hipótesis y verificar supuestos, generalmente apoyándose en estadísticas descriptivas y visualizaciones.

Objetivos principales

- Comprender la estructura y distribución de los datos.
- Identificar valores atípicos (*outliers*) y datos faltantes.
- Detectar relaciones y correlaciones entre variables.
- Validar la calidad de los datos antes de modelarlos.
- Generar hipótesis iniciales para análisis posteriores.

Herramientas comunes

- Histogramas, diagramas de caja (*boxplots*), gráficos de dispersión.
- Medidas estadísticas: media, mediana, desviación estándar, cuartiles.
- Librerías: Pandas, Matplotlib, Seaborn (Python) o ggplot2 (R).

3 ¿Qué es SQL?

Definición

SQL (*Structured Query Language* — Lenguaje de Consulta Estructurada) es un lenguaje estándar utilizado para gestionar y manipular bases de datos **relacionales**, organizadas en tablas con filas y columnas relacionadas entre sí mediante claves.

Principales tipos de comandos

- **DDL** (*Data Definition Language*): **CREATE**, **ALTER**, **DROP** — definen la estructura.
- **DML** (*Data Manipulation Language*): **SELECT**, **INSERT**, **UPDATE**, **DELETE** — manipulan los datos.
- **DCL** (*Data Control Language*): **GRANT**, **REVOKE** — gestionan permisos.
- **TCL** (*Transaction Control Language*): **COMMIT**, **ROLLBACK** — controlan transacciones.

Características clave

- Estructura de datos fija (esquema definido previamente).
- Garantiza integridad mediante relaciones y claves primarias/foráneas.
- Cumple con propiedades **ACID** (Atomicidad, Consistencia, Aislamiento, Durabilidad).
- Ejemplos de motores: MySQL, PostgreSQL, SQL Server, Oracle.

4 ¿Qué es NoSQL?

Definición

NoSQL (*Not Only SQL*) se refiere a bases de datos **no relacionales**, diseñadas para almacenar datos con estructuras flexibles o sin esquema fijo, pensadas para manejar grandes volúmenes de información, alta velocidad y escalabilidad horizontal.

Tipos de bases de datos NoSQL

- **Documentales**: almacenan datos como documentos (ej. JSON/BSON) — *MongoDB*.
- **Clave-valor**: pares simples de clave y valor — *Redis*, *DynamoDB*.
- **Columnares**: organizan datos por columnas — *Cassandra*, *HBase*.
- **De grafos**: modelan relaciones complejas entre entidades — *Neo4j*.

SQL vs. NoSQL

Característica	SQL	NoSQL
Esquema	Fijo y estructurado	Flexible / dinámico
Escalabilidad	Vertical (más potencia)	Horizontal (más servidores)
Relaciones	Fuertes (joins)	Limitadas o embebidas
Casos de uso	Transacciones, sistemas contables	Big Data, tiempo real, IoT

5 ¿Qué es MongoDB?

Definición

MongoDB es una base de datos **NoSQL orientada a documentos**. Almacena la información en documentos con formato **BSON** (una versión binaria de JSON), agrupados en *colecciones* en lugar de tablas.

Conceptos clave

- **Documento:** unidad básica de datos, similar a un objeto JSON.
- **Colección:** conjunto de documentos, equivalente a una tabla en SQL.
- **Base de datos:** contenedor de una o varias colecciones.
- Cada documento puede tener una estructura diferente (esquema flexible).

Ejemplo de documento

```
{
  "_id": "001",
  "nombre": "Ana Torres",
  "edad": 28,
  "intereses": ["datos", "programacion"]
}
```

Ventajas

Alta escalabilidad horizontal, flexibilidad de esquema, buen desempeño en lecturas/escrituras masivas y facilidad para trabajar con datos semiestructurados.

6 8 Pasos de la Transformación de Datos

1. **Descubrimiento (*Discovery*):** explorar y comprender el origen y la naturaleza de los datos disponibles.
2. **Mapeo de estructura (*Structuring*):** organizar los datos crudos en un formato utilizable, definiendo columnas y tipos.
3. **Limpieza (*Cleaning*):** corregir errores, eliminar duplicados y tratar valores nulos o inconsistentes.
4. **Enriquecimiento (*Enriching*):** añadir información adicional de otras fuentes para complementar el conjunto de datos.
5. **Validación (*Validating*):** verificar que los datos cumplan reglas de calidad, formato y consistencia.
6. **Estandarización (*Standardizing*):** unificar formatos (fechas, unidades, mayúsculas/minúsculas, monedas, etc.).
7. **Publicación (*Publishing*):** cargar los datos transformados en su destino final (data warehouse, base de datos, etc.).

8. **Monitoreo y mantenimiento (*Monitoring*):** supervisar continuamente la calidad y actualizar el proceso ante cambios en las fuentes.

Importancia

Estos pasos aseguran que los datos que llegan al análisis o a los modelos sean confiables, coherentes y estén listos para generar valor real.

7 ¿Qué hacer si tengo datos nulos?

Contexto

Los datos nulos (*missing values*) son valores ausentes en un conjunto de datos. Ignorarlos puede sesgar el análisis o romper modelos, por lo que deben tratarse de forma adecuada según su causa y proporción.

Estrategias comunes

1. **Eliminar filas o columnas:** si el porcentaje de nulos es muy alto o irrelevante para el análisis.
2. **Imputación por medidas estadísticas:** reemplazar con la media, mediana o moda de la variable.
3. **Imputación por modelos predictivos:** usar regresión, KNN u otros algoritmos para estimar el valor faltante.
4. **Relleno hacia adelante/atrás (*forward/backward fill*):** útil en series temporales, usando el valor anterior o posterior.
5. **Crear una categoría "Desconocido." "N/A":** en variables categóricas, para no perder el registro.
6. **Usar un valor constante:** como 0 o -1, cuando tiene sentido en el contexto del negocio.
7. **Marcar con una variable indicadora:** crear una columna binaria que indique si el dato era nulo, preservando esa información.

Recomendación

Antes de decidir la estrategia, es fundamental analizar **por qué** el dato es nulo (error de captura, dato no aplicable, pérdida de información, etc.), ya que esto determina el mejor tratamiento a seguir.